


Protein-Quanta

面向蛋白质-配体长时程动力学预测 的可控等变学习

初赛方案与阶段性实验结果

魏子安 · 耿健尧 · 熊润 | 2026.08



从稳定基线出发，只学习有证据支持的动力学修正

任务不是逐帧回归，而是受约束的长序列外推

半柔性设定：蛋白质固定，输入已观测的配体原子坐标，预测后续三维轨迹。

T1

10 → 10

短历史、短预测

考察初速度估计和局部几何

T2

80 → 20

长历史、短预测

考察历史信息利用和局部精度

T3

20 → 80

短历史、长预测

最容易出现闭环漂移和动力学坍塌

核心矛盾

误差要低，但不能靠“几乎不动”获得低误差。

三个问题决定了模型能否真正学到动力学

01

闭环漂移

前一步误差会进入下一步输入，T3 的 80 帧推演会持续放大偏差。

时间

02

三维对称性

整体旋转和平移不应改变内在动力学，坐标更新必须满足 $E(3)$ 等变。

空间

03

运动坍塌

低 RMSE 可能来自近静态预测，必须同时检查步幅、速度和稳定性。

评价

我们的判断：更大的序列模型不是充分条件；单位、等变性和闭环训练目标必须同时正确。

研究路线：先复现，再让创新承担可证伪的目标

每个候选先过正确性门槛，再过效果门槛；失败结果同样用于决定下一步。



完整 MISATO 数据链路已经打通

先确保数据和复现口径可靠，再讨论模型优劣。

16,972

HDF5 复合物

group ID 与三份原始 split 的并集完全一致

13,066

过滤后训练集

验证集与测试集均为 1,357；去除 peptides


48 / 48

抽样审计通过

schema、坐标有限性和数据读取全部通过

- 全量文件大小 132,841,014,019 字节；MD5 与公开值一致。
- Published NeuralMD 仍作为主基线，候选未通过联合门槛前不替换。
- 流式数据集已完成真实样本 GPU 前向/反向，梯度有限且非零。
- Top-k 16/32/64/128 实测均慢于 dense，当前不采用稀疏邻域。

先修正单位：步幅恢复不等于长程预测正确



Zero-acceleration analytic control; T1/T2/T3 follow the updated guide. Amplitude recovery is not a performance gain: long-horizon constant velocity drifts.

0.916-1.028

单位修正后的步幅比

解析控制证明初速度缩放应与时间尺度一致。

33.88 Å


恒速度模型 T3 RMSE

数值约定正确以后，长程漂移仍然存在。

结论：单位一致性是必要条件，但不能代替动力学建模。

多时间尺度闭环在长程代理任务上出现稳定信号

12 维轨迹不变量代理任务，三随机种子；结果用于验证机制，不等同于三维正式成绩。



-5.59%

T3 RMSE

0.50540 → 0.47716; 三个种子方向一致

-2.97%


宏平均 RMSE

0.40821 → 0.39609; 主要收益集中在 T3

机制可迁移，三维效果仍待验证

一次“看起来很好”的结果暴露了评价陷阱

36/12 train-only 开发划分：速度感知 E(3) 相对 position-only 控制。



0.1135

T3 步幅比

98.3%

梯度裁剪率


模型不是学得更准，而是过度刹车

-
- 速度信息有用：正确性和 RMSE 都出现正信号。
- 单一坐标指标不够：动力学幅度和优化稳定性必须联合判断。

综合门槛：不晋升

恢复运动幅度以后，轨迹方向仍然可能错

完整训练集新抽取的 32/8 train-only 配对实验； validation/test 未访问。



0.6014

候选 T3 步幅比

control 为 0.0763，运动幅度明显恢复

+278%


候选 T3 RMSE

6.239 Å → 23.586 Å，轨迹误差严重恶化

幅度改善不能抵消坐标失败：方案冻结

创新点：从稳定控制出发，学习受限的等变修正

control-anchored gated E(3) residual



$$a = a_anchor + gate(z, |v|^2) \cdot \tanh(s) \cdot a_residual$$

目标：避免自由残差再次走向静止或 ballistic，同时保留可学习性。

锚定式残差已通过 7/7 项结构正确性门槛

真实训练复合物 4K6V；只做一次更新，不访问 diagnostic、validation 或 test。

0.0

初始 anchor 误差

初始化输出与冻结 control 严格一致

-3.34e-6

尺度梯度

有限且非零，残差分支可训练

6.59e-8

相对修正幅度

单步后非零且远低于 5% 上限

bitwise

锚点保持不变

冻结控制参数逐位一致

E(3) 等变误差

旋转 2.086×10^{-7}

反射 2.682×10^{-7}

全部低于 1e-4 门槛

这证明结构可实现、可训练且初始安全；尚不等同于预测性能提升。

模型晋升看四个维度，也要守住数据边界

Geo

坐标 RMSE
等变误差

Phys

局部几何
碰撞代理

Dyn

步幅与速度
闭环漂移

Stab

裁剪率
跨 seed 稳定

外部预训练模型的处理原则

- PVB、EPT、DPLM、ProTDyn 目前只作为架构参考。
- 训练 ID、近同源和配体 scaffold 未审计清楚前，不加载权重。

为什么这样做

比赛明确要求外部数据不能包含测试复合物或近同源体系。短期少用一个预训练模型，比得到无法解释的高分更重要。

不自行拼接新版未公布的官方总分

复现链路和团队能力已经形成闭环

复现与开放

- 公开仓库保存配置、随机种子、原始 JSON 和逐项实验报告。
- 固定 NeuralMD、MISATO 和官方 checkpoint 的提交与哈希。
- 数据与第三方权重不进入 Git，只记录合法来源和校验值。
- 当前训练评估不依赖商业 API 或闭源模型。

github.com/ytq0198/Protein-Quanta

团队

魏子安 | 研究路线、复现、长序列实验
耿健尧 | 文献、合规、结果复核
熊 润 | 三维模型、完整训练、GPU 优化



已有协作经验

古文字识别智能体项目
第四届世界科学智能大赛
古文字识别赛道三等奖

下一步只回答一个问题：受控残差能否同时改善精度和运动？

- | | | |
|----|---------------------|---|
| 01 | 8/4 train-only 效果门槛 | 冻结 control, 与 anchored residual 同 schedule 配对 |
| 02 | 联合判定 | T3 RMSE、T3 步幅、T1 防线、残差能量同时通过 |
| 03 | 三维多尺度迁移 | 把 [5,10,20,40] 闭环监督加入等变模型 |
| 04 | 完整训练与泄漏审计 | 同源蛋白、Bemis-Murcko scaffold、外部权重全量披露 |

我们的目标不是把模型做得更复杂，而是让每一次改进都有可复核的科学理由。